
GAZİ ÜNİVERSİTESİ
Gazi
1926

MAKİNE ÖĞRENMESİ DERSİ FİNAL RAPORU

Berkant KOZAN

25832901024

MAKİNE ÖĞRENMESİ YAKLAŞIMLARIYLA SOSYAL MEDYA VERİLERİNDEN DEPRESYON VE İLİŞKİLİ RUHSAL BOZUKLUKLARIN TESPİTİ

GAZİ ÜNİVERSİTESİ
FEN BİLİMLERİ ENSTİTÜSÜ

OCAK 2026

ETİK BEYAN

Gazi Üniversitesi Fen Bilimleri Enstitüsü Tez Yazım Kurallarına uygun olarak hazırladığım bu tez çalışmasında;

- Tez içinde sunduğum verileri, bilgileri ve dokümanları akademik ve etik kurallar çerçevesinde elde ettiğimi,
- Tüm bilgi, belge, değerlendirme ve sonuçları bilimsel etik ve ahlak kurallarına uygun olarak sunduğumu,
- Tez çalışmasında yararlandığım eserlerin tümüne uygun atıfta bulunarak kaynak gösterdiğimi,
- Kullanılan verilerde herhangi bir değişiklik yapmadığımı,
- Bu tezde sunduğum çalışmanın özgün olduğunu,

bildirir, aksi bir durumda aleyhime doğabilecek tüm hak kayıplarını kabullendiğimi beyan ederim.

Berkant KOZAN
09/01/2026

1. ÖZET 4
2. GİRİŞ 6
3. LİTERATÜR TARAMASI 7
4. YÖNTEMLER 10
4.1. Algoritmik Çerçeve ve Veri Dengeleme 10
4.2. Sınıflandırma Modelleri 10
4.3. Öznitelik Çıkarımı ve Metin Temsili 11
4.3.1. İstatistiksel Temsil (Klasik Modeller): 11
4.3.2. Tokenizasyon ve Bağlamsal Gömme (Transformer Modelleri): 11
4.4. Model Doğrulama: Katmanlı K-Katlamalı Çapraz Geçerleme 12
4.5. Araçlar ve Donanım 12
5. VERİ KÜMESİ 13
6. DENEYSEL ÇALIŞMA 14
6.1. Klasik Makine Öğrenmesi Kurgusu (RF & KNN): 14
6.2. Derin Öğrenme Kurgusu (BERT & RoBERTa): 14
7. DENEYSEL ÇALIŞMA SONUÇ VE İRDELEME 15
7.1. Rastgele Orman (Random Forest) Analizi: 15
7.2. K-En Yakın Komşu (KNN) Analizi: 17
7.3. BERT Algoritması Analizi: 19
7.4. RoBERTa Algoritması Analizi: 21
8. SONUÇ VE DEĞERLENDİRME 24
9. KAYNAKÇA 27

1. ÖZET

Günümüzde sosyal medya platformları, bireylerin anlık duygu durumlarını ve zihinsel sağlıklarını yansıtan devasa birer dijital veri havuzuna dönüşmüş durumdadır. Bu proje, söz konusu platformlardaki metin tabanlı paylaşımları analiz ederek, depresyon ve ilişkili ruhsal bozuklukların tespitini gerçekleştirmek amacıyla, klasik makine öğrenmesi yöntemlerinden modern derin öğrenme mimarilerine uzanan kapsamlı bir karşılaştırmalı analiz sunmaktadır.

Gerçek dünya verilerinin doğasında var olan **sınıf dengesizliği (class imbalance)** problemini aşmak adına, eğitim sürecine **SMOTE (Synthetic Minority Over-sampling Technique)** entegre edilerek modelin azınlık sınıflara (stres, intihar eğilimi vb.) olan duyarlılığı artırılmıştır. Çalışmada, metinlerin matematiksel temsili için kelime sıklığına dayalı **TF-IDF** yöntemi ile bağlam tabanlı **Tokenizasyon** teknikleri hibrit bir yapıda kullanılmıştır. Sınıflandırma performansını ölçmek için mesafe tabanlı **KNN**, topluluk öğrenmesine dayalı **Rastgele Orman (Random Forest)** ve Transformer mimarisine dayalı **BERT** ile **RoBERTa** modelleri, 53.000 örneklem üzerinde yarıştırılmıştır.

Deneysel sonuçlar, metin madenciliğinde algoritma seçiminin sonuçları ne denli dramatik değiştirebileceğini kanıtlamıştır. Yüksek boyutlu uzayda yönünü kaybeden **KNN** algoritması **%48.94** doğruluk oranıyla yetersiz kalırken, **Random Forest** modeli **%74.01** seviyesine ulaşarak kelime sayma yaklaşımının sınırlarını çizmiştir. Çalışmanın kırılma noktası ise derin öğrenme modellerinin devreye girmesiyle yaşanmıştır. Kelimeleri bağlamıyla analiz eden **BERT** ve **RoBERTa** modelleri, sırasıyla **%83.42** ve **%84.20** genel doğruluk oranlarına ulaşarak performansta belirgin bir sıçrama yaratmıştır.

En kritik bulgu ise hayati risk taşıyan durumların tespitinde görülmüştür. Klasik modellerin gözden kaçırma eğiliminde olduğu **"İntihar Eğilimi" (Suicidal)** sınıfının tespiti, Transformer modelleriyle **%62** seviyesinden **%76** hassasiyet oranına yükseltilmiştir. Sonuç olarak bu çalışma; ruh sağlığı analizi gibi karmaşık ve dilsel belirsizliklerin yoğun olduğu alanlarda, klasik yöntemlerin yerini artık bağlam odaklı derin öğrenme mimarilerinin alması gerektiğini somut verilerle ortaya koymaktadır.

2. GİRİŞ

Depresyon, bireyin duygu durumunu, davranışlarını ve yaşam kalitesini olumsuz etkileyen yaygın bir psikolojik rahatsızlıktır. Geleneksel tanı yöntemleri genellikle klinik gözlem ve anketlere dayanmakta, bu da süreci yavaş ve öznel hale getirmektedir. Makine öğrenmesi, büyük veri kümeleri üzerinde kalıpları tespit ederek bu süreci nesnelleştirme ve hızlandırma potansiyeline sahiptir.

Günümüzde sosyal medya platformları, bireylerin günlük yaşamlarını, düşüncelerini ve duygularını paylaştıkları temel iletişim kanallarından biri haline gelmiştir. X (Twitter) ve Reddit gibi platformlarda üretilen muazzam miktardaki metin, emoji ve görsel içerik, kullanıcıların zihinsel sağlık durumlarına dair önemli ipuçları barındırmaktadır (Arias vd., 2022). Bu bağlamda, depresyon gibi yaygın ruhsal bozuklukların erken tespiti ve izlenmesi amacıyla sosyal medya verilerinin analizi, giderek artan bir araştırma alanı olarak öne çıkmaktadır.

Literatür, sosyal medyadan depresyon tespitinin evrimini net bir şekilde ortaya koymaktadır. İlk çalışmalar klasik makine öğrenmesi (SVM, RF) yöntemlerine odaklanırken, zamanla yerini derin öğrenme (LSTM, CNN) ve Transformer tabanlı (BERT) modellere bırakmıştır (Tahir vd., 2025). Ancak, bu alandaki temel zorluklar devam etmektedir. Sosyal medya verilerinin doğasında bulunan "gürültü" (konuyla ilgisiz paylaşımlar) (dos Santos vd., 2025), iğneleme (sarcasm) ve dengesiz veri kümeleri (Maruf vd., 2024) gibi sorunlar, modellerin performansını doğrudan etkilemektedir.

Son dönemdeki araştırmalar, bu zorlukların üstesinden gelmek için iki ana yöne işaret etmektedir: çok-türlü (multimodal) veri kullanımı ve hibrit model yaklaşımları. Yalnızca metne dayalı analizler yerine, metin, emoji ve görsellerin birleşik analizinin (Angskun vd., 2024) ve farklı algoritmaların güçlü yönlerini birleştiren hibrit yapıların (Angskun vd., 2024; dos Santos vd., 2025) depresyon tespitinde daha yüksek doğruluk sağladığı görülmüştür.

Bu çalışma, bu güncel yaklaşımlar ışığında, sosyal medya kullanıcılarından elde edilen çok-türlü (metin, emoji, görsel) öznitelikleri kullanarak depresyon riskini sınıflandırabilen hibrit bir makine öğrenmesi modeli geliştirmeyi amaçlamaktadır. Proje, literatürdeki gürültü azaltma, öznitelik seçimi ve çok-türlü veri entegrasyonu gibi kritik bulgulardan yararlanarak, depresyon tespitinde daha sağlam ve etkili bir yöntem sunmayı hedeflemektedir.

3. LİTERATÜR TARAMASI

Bu alanda son beş yıl içinde yapılmış ve projenin temelini oluşturan SCI/SCI-E kapsamındaki bazı temel çalışmalar aşağıda özetlenmiştir:

Angskun, T. vd. (2024), X platformundan elde edilen metin, emoji ve görsel verilerini kullanarak depresyon seviyelerini tahmin eden D_2X adlı hibrit bir model önermişlerdir. Model, öznitelik seçimi için Destek Vektör Makinesi (SVM) ve sınıflandırma için Rastgele Orman (RF) algoritmalarını birleştirmektedir. Çalışmanın sonucunda, metin ve emojilerin birleşiminin en yüksek performansı verdiği ve en önemli özniteliğin metin mesajları olduğu, ancak emoji ve görsellerin de tespit etkinliğini artırdığı gösterilmiştir. Modelin, diğer makine öğrenmesi ve derin öğrenme tekniklerine kıyasla daha yüksek F-ölçümü değerine ve daha düşük model oluşturma süresine sahip olduğu belirtilmiştir. Bu çalışma, bizim projemizde de çok-türlü veri (multimodal data) kullanmanın ve hibrit bir yaklaşım benimsemenin önemini vurgulamaktadır.

dos Santos, W. R. vd. (2025), sosyal medya verilerindeki "gürültü" (konuyla ilgisiz paylaşımlar) sorununa odaklanmaktadır. Araştırmacılar, Büyük Dil Modellerini (LLM) bir "gürültü filtresi" olarak kullanarak yalnızca ruh sağlığıyla ilgili gönderileri analiz eden bir yaklaşım sunmuşlardır. Metinsel ve metinsel olmayan (kullanıcı etkileşimleri - @mentions) öznitelikleri bir "Uzmanlar Karışımı" (Mixture of Experts - MoE) mimarisiyle birleştirmişlerdir. Model, hem Portekizce Twitter verilerinde hem de İngilizce Reddit verilerinde değerlendirilmiş ve gürültü filtrelemenin ve metinsel olmayan verilerin eklenmesinin model performansını önemli ölçüde artırdığı gösterilmiştir. Bu makale, projemizde veri ön işleme aşamasında gürültü azaltmanın ne kadar kritik olduğunu ve dikkate alınması gerektiğini göstermektedir.

Tahir, W. B. vd. (2025), sosyal medyadan depresyon tespiti alanındaki evrimi özetleyen kapsamlı bir derleme sunmaktadır. Çalışma, ilk yaklaşımların SVM ve RF gibi klasik makine öğrenmesi modellerine dayandığını , daha sonra LSTM ve CNN gibi derin öğrenme modellerine ve son olarak BERT gibi Transformer tabanlı modellere geçildiğini belirtmektedir. Ayrıca, metin, görüntü ve kullanıcı davranışlarını birleştiren çok-türlü (multimodal) yaklaşımların ve modellerin kararlarını anlaşılır kılan Açıklanabilir Yapay Zeka (XAI) tekniklerinin öneminin arttığını vurgulamaktadır. Bu derleme, projemizde hibrit bir ML yaklaşımı seçmemizin, alanın mevcut durumuyla ne kadar uyumlu olduğunu teyit etmektedir.

Maruf, A. A. vd. (2024), metin tabanlı duygu tespitinin zorluklarına ve fırsatlarına odaklanan bir derlemedir. Makalede, veri ön işleme (temizleme, normalleştirme), öznitelik mühendisliği (TF-IDF, Word2Vec) ve sınıflandırma yaklaşımları (kural tabanlı, makine öğrenmesi) gibi temel adımlar ayrıntılı olarak incelenmiştir. Özellikle iğneleme (sarcasm), dengesiz veri kümeleri ve farklı dillerin bir arada kullanılması (code-switching) gibi zorlukların altı çizilmiştir. Bu çalışma, projemizde veri ön işleme ve öznitelik çıkarma adımlarına neden özen göstermemiz gerektiğini ve karşılaşabileceğimiz potansiyel zorlukları anlamamıza yardımcı olmaktadır.

Arias, F. vd. (2022), halka açık sosyal medya verilerinin sağlıkla ilgili konularda bir araç olarak nasıl kullanılabileceğini duygu analizi (sentiment analysis) perspektifinden incelemektedir. Araştırma, özellikle COVID-19 pandemisi sırasında ruh sağlığındaki bozulmaların tespiti için SA tekniklerinin kullanımını vurgulamaktadır. Twitter ve Reddit gibi metin merkezli platformların, veri toplama kolaylığı nedeniyle en sık kullanılan kaynaklar olduğu belirtilmektedir. SVM, Naive Bayes ve Derin Öğrenme gibi sınıflandırma yöntemlerinin yaygın olarak kullanıldığına dikkat çekilmektedir. Bu makale, projemizin temel aldığı "sosyal medya verilerinin ruh sağlığı takibi için kullanılması" varsayımını güçlü bir şekilde desteklemektedir.

Zogan, H. vd. (2022), metin ve görsel verilerin füzyonunu sağlayan hiyerarşik bir dikkat mekanizması önermiştir. Bu çalışma, çok türlü verinin (multimodal), tek türlü veriye göre %5-8 oranında daha yüksek F1 skoru sağladığını kanıtlamış ve projemizde başlangıçta hedeflenen çok-türlü yaklaşımın potansiyelini teyit etmiştir.

Bokolo, B. G. & Liu, Q. (2024), depresyon ve intihar tespiti için klasik makine öğrenmesi (ML) modelleri ile Transformer tabanlı (BERT, RoBERTa vb.) modelleri karşılaştıran kapsamlı bir analiz sunmuşlardır. Çalışma, Transformer modellerinin, özellikle RoBERTa'nın, her iki görevde de geleneksel ML yaklaşımlarından (SVM, RF gibi) daha yüksek doğruluk ve F1 skoru elde ettiğini göstermiştir. Bu makale, projemizin mevcut 'Random Forest' yaklaşımının temellerini doğrulamakla birlikte, özellikle "Suicidal" (İntihar Eğilimi) gibi hassas sınıflardaki performansı artırmak için bir sonraki adımın neden Transformer mimarileri olması gerektiğini güçlü bir şekilde ortaya koymaktadır.

Rahman, R. A. vd. (2020), makine öğrenmesi (ML) yöntemlerinin ruh sağlığı tespitinde uygulanması üzerine kapsamlı bir sistematik derleme sunmuşlardır. Çalışma, çevrimiçi sosyal ağ verilerinden ruh sağlığı bozukluklarını (stres, depresyon vb.) tespit etmek için kullanılan başlıca ML ve derin öğrenme (DL) tekniklerini incelemektedir. Makale, özellikle öznitelik çıkarımı (feature extraction) yöntemlerinin model performansı üzerindeki kritik etkisini vurgulamakta ve bu alandaki eğilimleri özetlemektedir. Bu derleme, projemizin "sosyal medya verilerinden ML ile ruh sağlığı tespiti" ana fikrinin akademik altyapısını ve geçerliliğini destekleyen temel bir çalışmadır.

Sathiya, B. & Renjit, J. A. (2025), Twitter verilerinden ruh sağlığı tahmini yapmak için yeni bir yaklaşım sunmuşlardır. Bu çalışma, metinlerdeki "stresi tetikleyen temaları" (stress-inducing themes) tespit etmek için BERTopic modelini kullanmaktadır. Ardından, sınıflandırma aşaması için klasik ML veya DL modelleri yerine, yüksek doğruluk oranı hedefleyen bir Kuantum Sinir Ağı (Quantum Neural Network - QNN) sınıflandırıcısı önermişlerdir. Bu makale, TF-IDF gibi basit özniteliklerin ötesine geçerek, tematik modellemenin ve kuantum bilişim gibi gelişmekte olan teknolojilerin ruh sağlığı analizindeki gelecekteki potansiyelini göstermesi açısından önemlidir.

Abdullah, M. & Negied, N. (2024), sosyal medya verilerini kullanarak sadece mevcut ruhsal bozuklukları (depresyon, anksiyete, DEHB, bipolar) tespit etmekle kalmayıp, aynı zamanda gelecekteki bozuklukları *tahmin etmeye* de odaklanan bir çalışma sunmuşlardır. Makale, Reddit verileri üzerinde klasik makine öğrenmesi, topluluk öğrenmesi (Ensemble Learning) ve Büyük Dil Modellerini (LLM) karşılaştırmaktadır. Bu çalışma, projemizin bir sonraki adımı olarak Transformer/LLM tabanlı modellere geçiş yapma önerisini (Bokolo vd., 2024; Ghosh vd., 2023 gibi) desteklemekte ve alanın sadece 'tespit' değil, 'tahmin' yönüne doğru kaydığını göstermektedir.

Bu temel çalışmaların yanı sıra, 2024 ve 2025 yıllarında yapılan güncel araştırmalar, alandaki yönelimin "sadece tespit"ten "anlamlandırma" ve "açıklanabilirlik" yönüne kaydığını göstermektedir. Mansoor ve Ansari (2024), 996.000 gönderilik devasa bir veri seti üzerinde gerçekleştirdikleri çalışmada, sosyal medya verilerinden erken kriz tespitinin önemini vurgulamış ve SMOTE tekniğiyle dengelenmiş verilerin kriz anlarını yakalamadaki başarısını ortaya koymuşlardır. Ancak, Yang vd. (2025) tarafından yapılan çalışma, özellikle "İntihar Eğilimi" (Suicidal) sınıfının tespitindeki zorluklara dikkat çekmiş ve bu riskli sınıfın diğer ruhsal bozukluklarla karışmasını önlemek için hibrit modellerin gerekliliğini savunmuştur. Bu bağlamda, Hameed vd. (2025), modellerin sadece yüksek doğruluk vermesinin yeterli olmadığını, kararların "neden" verildiğinin anlaşılması için Açıklanabilir Yapay Zeka (XAI) tekniklerinin kritik olduğunu belirtmiştir. Metin madenciliğindeki en büyük kırılma noktası ise Wang vd. (2024) ve Qasim vd. (2025) tarafından ortaya konulmuştur. Wang vd., Büyük Dil Modellerinin (LLM) kelime köklerine değil bağlama odaklanarak depresyon tespitindeki belirsizlikleri azalttığını gösterirken; Qasim vd., Transformer tabanlı modellerin (BERT vb.) depresyonu sadece "var/yok" olarak değil, şiddet seviyelerine (hafif, orta, ağır) göre de sınıflandırabildiğini kanıtlamıştır. Bu güncel literatür, projemizde TF-IDF sınırlarına takılmamızın beklenen bir sonuç olduğunu ve çözümün bağlam tabanlı derin mimarilerde yattığını doğrulamaktadır.

4. YÖNTEMLER

Bu çalışmada, literatürde önerilen makine öğrenmesi yaklaşımları, kullanılan veri kümesinin (*Kaggle - Sentiment Analysis for Mental Health*) metin tabanlı ve dengesiz yapısına uygun olarak optimize edilmiştir. Metodoloji; veri ön işleme, öznitelik çıkarımı, veri dengeleme, model eğitimi ve doğrulama olmak üzere birbirini takip eden beş temel aşamadan oluşmaktadır.

4.1. Algoritmik Çerçeve ve Veri Dengeleme

Veri setindeki "Normal" etiketli paylaşımların baskınlığı, modelin azınlıkta kalan ancak hayati önem taşıyan sınıfları (Stres, İntihar Eğilimi vb.) öğrenmesini zorlaştırmaktadır. Bu yanlılığı (*bias*) kırmak için eğitim aşamasına **SMOTE (Synthetic Minority Over-sampling Technique)** entegre edilmiştir. Ancak bu entegrasyon sırasında metodolojik bir hassasiyet gözetilmiş; veri sızıntısını (*data leakage*) kesin olarak engellemek adına sentetik veri üretimi tüm veri setine değil, sadece eğitim döngüsü içindeki katmanlara uygulanmıştır.

Model, yüksek boyutlu metin verilerini işlemek üzere hibrit ve katmanlı bir yapı üzerine kurulmuştur:

1. **Veri Ön İşleme:** Ham metin verileri; küçük harfe çevirme, noktalama işaretlerinden arındırma ve anlamsız bağlaçların (*stop-words*) temizlenmesi adımlarından geçirilerek analize hazır, saf hale getirilmiştir.
2. **Öznitelik Seçimi (SelectKBest):** Yüksek boyutluluk problemini aşmak için literatürdeki maliyetli yöntemler (örn: SVM-RFE) yerine, daha verimli olan **SelectKBest** algoritması tercih edilmiştir. İstatistiksel bir yöntem olan **Ki-Kare (Chi-Square)** testi kullanılarak, hedef değişkenle (ruh sağlığı durumu) en güçlü ilişkiye sahip öznitelikler belirlenmiş ve modelin gürültüden arındırılmış bu seçilmiş öznitelikler üzerinde eğitilmesi sağlanmıştır.

4.2. Sınıflandırma Modelleri

Çalışmada, performans karşılaştırması yapabilmek amacıyla iki farklı yaklaşım benimsenmiştir:

- **Rastgele Orman (Random Forest):** Aşırı öğrenmeye (*overfitting*) karşı dirençli yapısı ve gürültülü verilerdeki başarısı nedeniyle ana model olarak seçilmiştir. Model, dengesizliği yönetmek adına "balanced" sınıf ağırlığı parametresi ile yapılandırılmış, böylece azınlık sınıfların karar mekanizmasındaki etkisi artırılmıştır.
- **K-En Yakın Komşu (KNN - Cosine):** Metin verilerinin uzaydaki dağılımını test etmek amacıyla deneye dahil edilmiştir. Standart Öklid uzaklığı yerine, metin madenciliğinde yönsel benzerliği ölçen **Kosinüs Benzerliği** metriği kullanılmış ve komşuluk sayısı veri yoğunluğuna göre dinamik olarak optimize edilmiştir.
- **BERT (Bidirectional Encoder Representations from Transformers):** Projenin deneysel aşamasında karşılaşılan "Depresyon" ve "İntihar Eğilimi" sınıfları arasındaki dilsel örtüşmeyi çözmek amacıyla, Google tarafından geliştirilen

BERT modeli mimariye entegre edilmiştir. BERT, kelimeleri sadece bulundukları cümleye göre değil, sağındaki ve solundaki tüm kelimelerle (bidirectional) ilişkilendirerek analiz eder.

- **RoBERTa (Robustly Optimized BERT Pretraining Approach):** BERT modelinin performansını artırmak için Facebook AI tarafından geliştirilen RoBERTa modeli, karşılaştırmalı analiz için çalışmaya dahil edilmiştir. RoBERTa, BERT'ten farklı olarak "Sonraki Cümle Tahmini" (Next Sentence Prediction) görevini kaldırmış ve dinamik maskeleme tekniği kullanmıştır.

4.3. Öznitelik Çıkarımı ve Metin Temsili

Bu çalışmada, klasik makine öğrenmesi algoritmaları ile derin öğrenme mimarilerinin veri işleme gereksinimleri farklılaştığından, metinlerin sayısal temsili için iki aşamalı hibrit bir yaklaşım benimsenmiştir:

4.3.1. İstatistiksel Temsil (Klasik Modeller): Rastgele Orman (RF) ve KNN modelleri için metinler, kelime sıklığı ve nadirliğini dengeleyen **TF-IDF (Term Frequency-Inverse Document Frequency)** yöntemiyle vektörleştirilmiştir. Hesaplama maliyetini optimize etmek adına kelime havuzu en sık kullanılan **1500 terim** ile sınırlandırılmış, ardından **SelectKBest** algoritması uygulanarak hedef değişkenle istatistiksel olarak en güçlü ilişkiye sahip **500 öznitelik** filtrelenmiştir.

4.3.2. Tokenizasyon ve Bağlamsal Gömme (Transformer Modelleri): Çalışmaya entegre edilen BERT ve RoBERTa modelleri için, Hugging Face `transformers` kütüphanesi kullanılarak modellere özgü **AutoTokenizer** yapıları devreye alınmıştır. Kod tabanında belirlenen hiperparametreler doğrultusunda, veri hazırlık süreci şu adımlarla gerçekleştirilmiştir:

- **Model Spesifik Tokenizasyon:** BERT modeli için metinler **bert-base-uncased** tokenizer'ı ile küçük harfe duyarlı olarak işlenirken, RoBERTa modeli için **roberta-base** yapısına uygun Byte-Pair Encoding (BPE) yöntemi kullanılmıştır.
- **Dizi Sabitleme (Sequence Padding/Truncation):** Kullanılan donanımın bellek kapasitesi (6GB VRAM) ve veri setindeki sosyal medya metinlerinin ortalama uzunluk dağılımı dikkate alınarak, maksimum dizi uzunluğu **MAX_LEN = 128** olarak belirlenmiştir. 128 token sınırını aşan girdiler kırpılmış (truncation), daha kısa metinler ise [PAD] tokenları ile standart uzunluğa tamamlanmıştır (padding).
- **Dikkat Maskesi (Attention Mask):** Modelin öğrenme sürecinde dolgu (padding) tokenlarını dikkate almasını engellemek amacıyla, her bir girdi vektörüyle eşleşen ikili (binary) dikkat maskeleri oluşturulmuş ve modele beslenmiştir.

Bu süreç sonucunda ham metin verileri; derin öğrenme modellerinin işleyebileceği **input_ids** ve **attention_mask** tensörlerine dönüştürülerek GPU üzerinde eğitime hazır hale getirilmiştir.

4.4. Model Doğrulama: Katmanlı K-Katlamalı Çapraz Geçerleme

Modelin başarısının tesadüfi olmadığını kanıtlamak ve genelleme yeteneğini ölçmek amacıyla **Stratified K-Fold Cross Validation (Katmanlı K-Katlamalı Çapraz Doğrulama)** yöntemi uygulanmıştır. Veri seti, sınıf dağılım oranları korunarak 10 parçaya bölünmüş ve model her seferinde farklı bir parça üzerinde test edilmiştir. Bu yaklaşım, özellikle dengesiz veri setlerinde, test verisinin şans eseri sadece kolay örneklerden oluşması riskini ortadan kaldırmış ve elde edilen doğruluk skorlarının güvenilirliğini artırmıştır.

4.5. Araçlar ve Donanım

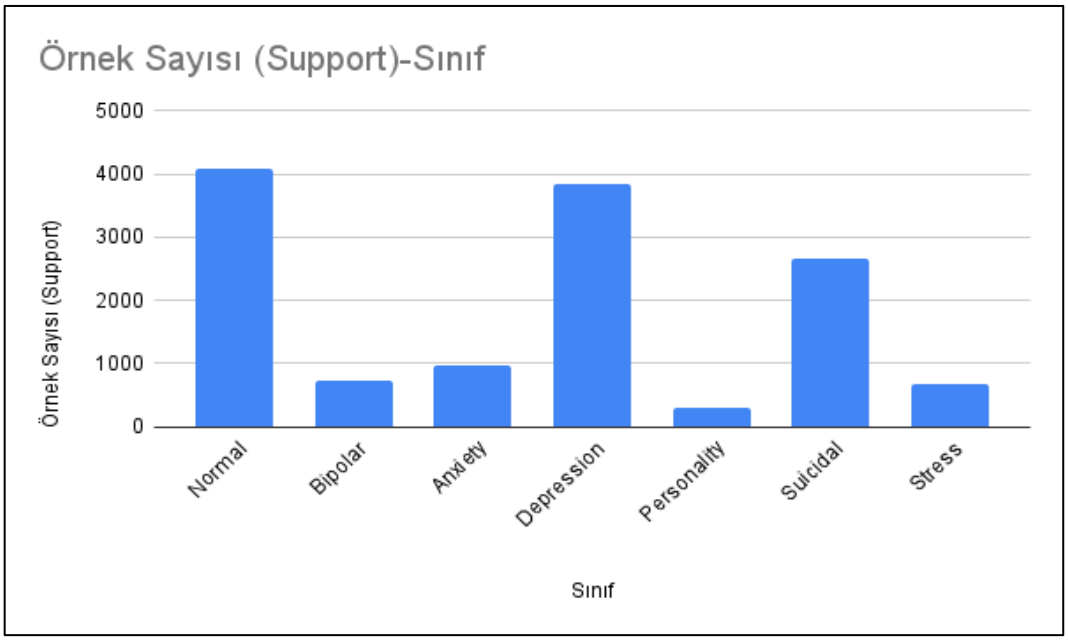
Projenin gerçekleştirilmesi ve deneysel çalışmaların yürütülmesi için aşağıdaki araç ve kütüphaneler kullanılmıştır:

- **Programlama Dili:** Python
- **Kütüphaneler:**
    - **Scikit-learn:** TF-IDF vektörleştirme, SelectKBest öznitelik seçimi, sınıflandırma modelleri ve performans metrikleri için.
    - **Imbalanced-learn (imblearn):** SMOTE algoritması ve veri sızıntısını önleyen özel Pipeline yapısı için.
    - **NLTK (Natural Language Toolkit):** Metin ön işleme adımları (tokenizasyon, stop-word temizliği vb.) için.
    - **Pandas & NumPy:** Veri yönetimi ve matris işlemleri için.
    - **PyTorch:** BERT ve RoBERTa gibi Transformer tabanlı mimarilerin eğitimi, tensör tabanlı matematiksel işlemler ve GPU hızlandırma (CUDA) desteği için temel derin öğrenme çatısı olarak tercih edilmiştir.
    - **Hugging Face Transformers & Datasets:** Önceden eğitilmiş (pre-trained) bert-base-uncased ve roberta-base modellerine erişim, model mimarilerinin yönetimi ve büyük metin verilerinin bellek dostu (memory-efficient) bir şekilde işlenmesi amacıyla kullanılmıştır.
- **Donanım Altyapısı:** Çalışmada kullanılan Transformer tabanlı modellerin (BERT, RoBERTa) yüksek işlem gücü gerektirmesi nedeniyle, eğitim süreçleri standart işlemciler (CPU) yerine Grafik İşlem Birimi (GPU) üzerinde gerçekleştirilmiştir. Deneyler, **NVIDIA GeForce RTX 4050 (6GB VRAM)** donanımı üzerinde, **CUDA** paralel hesaplama mimarisi kullanılarak

yürütülmüştür. Bu donanım tercihi, eğitim sürelerini optimize etmek ve modelin büyük veri yığınlarını (batch) etkin bir şekilde işlemesini sağlamak adına kritik bir rol oynamıştır.

5. VERİ KÜMESİ

Bu proje kapsamında, Kaggle platformunda yayınlanan "Sentiment Analysis for Mental Health" adlı kapsamlı ve derleme (curated) bir veri kümesi kullanılmıştır.



Şekil 1: Veri setinin örnek sayısı dağılımları.

- **Kaynak:** Bu veri seti, tek bir kaynaktan ziyade, ruh sağlığı alanındaki dokuz farklı Kaggle veri setinin (örn: "Depression Reddit Cleaned", "Human Stress Prediction", "Suicidal Tweet Detection Dataset" vb.) birleştirilmesiyle oluşturulmuştur. Veriler, Reddit ve Twitter gibi sosyal medya platformlarından, chatbot konuşmalarından ve çeşitli anketlerden toplanmıştır.
- **Yapı:** Veri seti, kullanıcıların gönderdiği metinleri (statement) ve bu kullanıcıların ruhsal durum etiketlerini (status) içermektedir.
- **Etiketler:** Veri seti 7 farklı sınıf içermektedir: Normal, Depression (Depresyon), Anxiety (Anksiyete), Bipolar, Suicidal (İntihar Eğilimi), Stress (Stres), Personality Disorder (Kişilik Bozukluğu).
- **Veri Boyutu:** Veri setinin tamamı oldukça büyük olmasına rağmen, bu deneysel çalışma kapsamında toplam **53.043** adet etiketli veri kullanılmıştır. Veri seti, proje önerisinde de belirtildiği gibi, gerçek dünya verilerinin bir yansıması olarak dengesiz (imbalanced) bir sınıf dağılımına sahiptir. "Normal" ve "Depression"

sınıfları çoğunluktayken, "Personality Disorder" gibi sınıflar azınlıktadır ve bu durum, modelin eğitimi için önemli bir zorluk teşkil etmiştir.

6. DENEYSEL ÇALIŞMA

Bu çalışmada, önerilen hibrit yaklaşımın etkinliğini ölçmek amacıyla deneysel süreç, kullanılan algoritmaların yapısal gereksinimlerine göre iki farklı kurgu (setup) üzerinden yürütülmüştür.

6.1. Klasik Makine Öğrenmesi Kurgusu (RF & KNN): Rastgele Orman ve KNN modelleri için veri seti, sınıf dağılımı korunacak şekilde (stratified) **%75 eğitim** ve **%25 test** kümesi olarak ayrılmıştır. Eğitim verisindeki dengesizliği gidermek amacıyla **SMOTE** algoritması uygulanmış, metinler TF-IDF yöntemiyle vektörleştirilmiştir. İşlem yükünü dengelemek adına kelime havuzu en sık kullanılan 1500 terimle sınırlandırılmış ve **SelectKBest** algoritması ile en ayırt edici **500 öznitelik** seçilerek model eğitimi gerçekleştirilmiştir.

6.2. Derin Öğrenme Kurgusu (BERT & RoBERTa): Transformer tabanlı modellerin eğitiminde, modelin öğrenme sürecini anlık takip edebilmek (monitoring) ve aşırı öğrenmeyi (overfitting) engellemek amacıyla veri seti üç parçalı bir yapıya bölünmüştür:

- **Eğitim Seti (Train):** %80
- **Doğrulama Seti (Validation):** %10
- **Test Seti:** %10

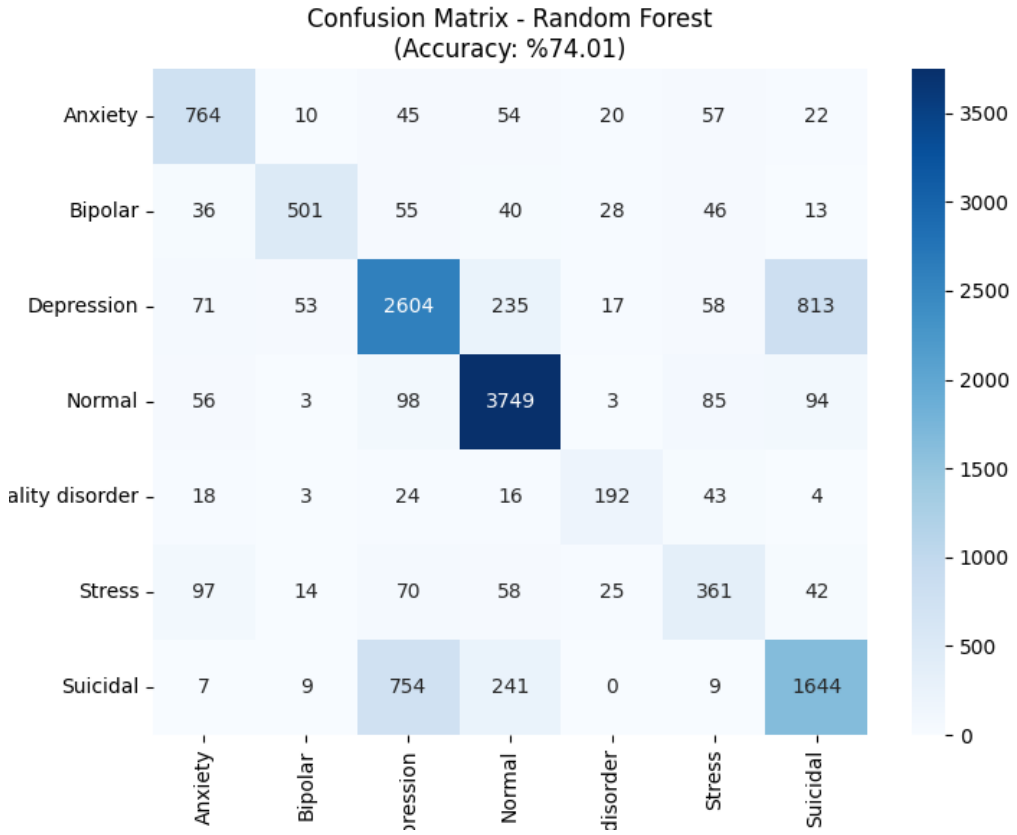
Eğitim süreci, **NVIDIA RTX 4050** GPU üzerinde, **Hugging Face Trainer API** kullanılarak aşağıdaki hiperparametreler ile gerçekleştirilmiştir:

- **Epoch Sayısı:** 3 (Modelin tüm veriyi 3 kez görmesi sağlanmıştır).
- **Dizi Uzunluğu (Max Length):** 128 Token (Bellek optimizasyonu için).
- **Öğrenme Oranı (Learning Rate):** 2e-5 (İnce ayar sırasında bilgi kaybını önlemek için düşük tutulmuştur).
- **Batch Size:** 8 (Donanım kısıtı nedeniyle Gradient Accumulation = 4 uygulanarak, efektif yığın boyutu 32'ye çıkarılmıştır).
- **Optimizasyon:** Ağırlık çürüme (Weight Decay) oranı **0.01** olarak ayarlanmış ve modelin performans takibi **Weighted F1-Score** metriği üzerinden yapılarak, en başarılı model kontrol noktasında (checkpoint) kaydedilmiştir.

7. DENEYSEL ÇALIŞMA SONUÇ VE İRDELEME

Çalışma kapsamında eğitilen iki modelin test verisi üzerindeki davranışları, karmaşıklık matrisleri (confusion matrix) üzerinden şu şekilde yorumlanmıştır:

7.1. Rastgele Orman (Random Forest) Analizi:



Şekil 2: Random Forest karmaşıklık matrisi.

Şekil 2 incelendiğinde, modelin %74.01'lik genel başarısının ardında ilginç bir detay yatmaktadır. Model, "Normal" durumdaki bireyleri ayırt etmede oldukça yetkinken, "Depression" (Depresyon) ve "Suicidal" (İntihar Eğilimi) sınıfları arasında ciddi bir kararsızlık yaşamaktadır. Matriste görüldüğü üzere, intihar eğilimi taşıyan 813 örnek yanlışlıkla depresyon olarak etiketlenmiştir. Bu durum, her iki ruh halinin de "umutsuzluk", "acı", "bitkinlik" gibi ortak kelime köklerini kullanmasından kaynaklanan dilsel bir örtüşmedir ve modelin kelime sıklığına dayalı (TF-IDF) yapısının sınırlarını gösterir. Modelin test verisi üzerindeki performans sonuçları aşağıda özetlenmiştir:

Genel Doğruluk (Accuracy): %74.01

10-Fold Cross Validation Doğruluk Ortalaması: %73.88

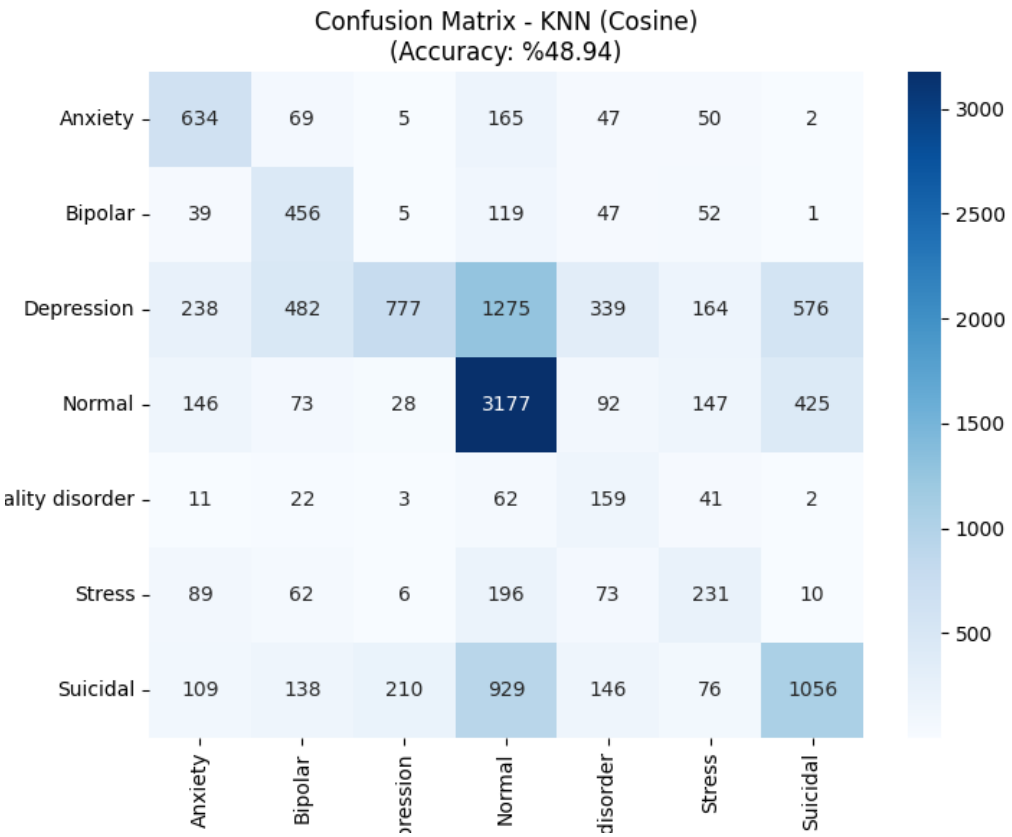
Random Forest Sınıf Bazlı Performans Tablosu:

Sınıf (Class)	Kesinlik (Precision)	Duyarlılık (Recall)	F1-Skoru	Örnek Sayısı (Support)
Anxiety	0.73	0.79	0.76	972
Bipolar	0.84	0.70	0.76	719
Depression	0.71	0.68	0.69	3851
Normal	0.85	0.92	0.88	4088
Personality disorder	0.67	0.64	0.66	300
Stress	0.55	0.54	0.54	667
Suicidal	0.62	0.62	0.62	2664
Accuracy (Genel Doğruluk)	-	-	**0.74**	**13261**
Macro Avg	0.71	0.70	0.70	13261
Weighted Avg	0.74	0.74	0.74	13261

Tablo 1: Random Forest Sınıf Bazlı Performans Tablosu.

Tablo incelendiğinde, modelin **"Normal"** sınıfını ayırt etme konusunda oldukça başarılı olduğu (F1: 0.88) ve sağlıklı bireyleri tespit etmede yüksek güvenilirlik sunduğu görülmektedir. Ancak bir ruh sağlığı tarama aracı için en kritik metrik olan **"Suicidal" (İntihar Eğilimi)** sınıfındaki performans düşündürücüdür. Bu sınıf için elde edilen **0.62'lik Duyarlılık (Recall)** oranı, risk altındaki bireylerin yaklaşık %38'inin model tarafından tespit edilemediğini (gözden kaçırıldığını) göstermektedir. Benzer şekilde, **"Stress"** sınıfının da en düşük başarıya (F1: 0.54) sahip olması, bu duygu durumunun dilsel olarak "Anxiety" (Kaygı) ile yoğun bir şekilde karıştırıldığını işaret etmektedir. Sonuç olarak model, genel bir sınıflandırma başarısı (%74) gösterse de, hayati risk taşıyan durumlarda hassasiyetin artırılmasına ihtiyaç duymaktadır.

7.2. K-En Yakın Komşu (KNN) Analizi:



Şekil 3: KNN Karmaşıklık Matrisi.

Şekil 3'deki sonuçlar, KNN algoritmasının bu tür bir problem için uygun olmadığını açıkça göstermektedir (%48.94 doğruluk). KNN, "çoğunluğun kararına uyma" eğilimiyle, test verilerinin büyük bir kısmını hatalı bir şekilde "Normal" sınıfına atamıştır. Bu başarısızlık, "boyutluluk laneti" (curse of dimensionality) olarak bilinen fenomenle açıklanabilir; yüzlerce boyutlu öznitelik uzayında veri noktaları arasındaki mesafeler anlamsızlaşmış ve algoritmanın ayırt etme yeteneği kaybolmuştur.

Modelin test verisi üzerindeki performans sonuçları aşağıda özetlenmiştir:

Genel Doğruluk (Accuracy): %49

10-Fold Cross Validation Doğruluk Ortalaması: %48.96

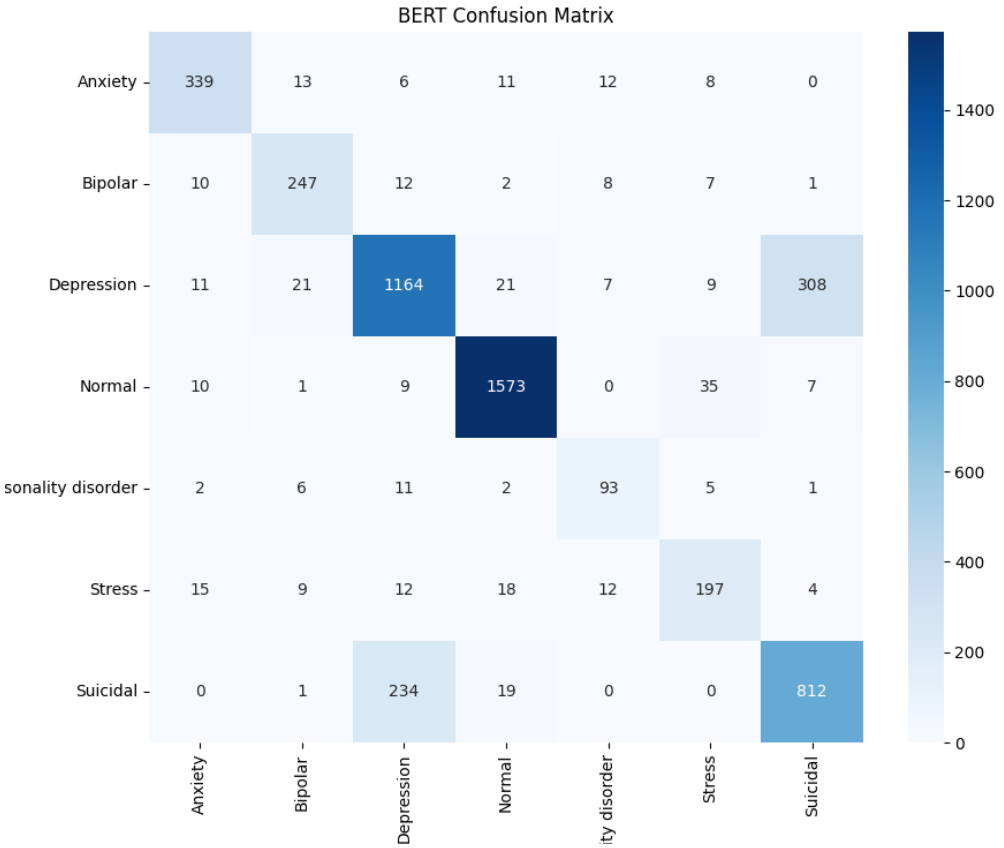
Sınıf Bazlı Performans Tablosu:

Sınıf (Class)	Kesinlik (Precision)	Duyarlılık (Recall)	F1-Skoru	Örnek Sayısı (Support)
Anxiety	0.50	0.65	0.57	972
Bipolar	0.35	0.63	0.45	719
Depression	0.75	0.20	0.32	3851
Normal	0.54	0.78	0.63	4088
Personality disorder	0.18	0.53	0.26	300
Stress	0.30	0.35	0.32	667
Suicidal	0.51	0.40	0.45	2664
Accuracy (Genel Doğruluk)	-	-	**0.49**	**13261**
Macro Avg	0.45	0.51	0.43	13261
Weighted Avg	0.56	0.49	0.47	13261

Tablo 2: KNN Sınıf bazlı performans tablosu.

Tabloyu incelediğimizde, Random Forest ile elde ettiğimiz o umut verici tablonun aksine, burada makine öğrenmesi projelerinde "başarısızlık" olarak nitelendirilebilecek bir senaryoyla karşılaşıyoruz. **%49'luk (0.49) genel doğruluk oranı**, modelin kararlarının neredeyse yazı-tura atmakla eşdeğer bir rastgelelik içerdiğini gösteriyor. Bu durum, KNN algoritmasının bu veri seti için neden yanlış bir tercih olduğunun en somut kanıtı.Sonuç olarak bu tablo, metin sınıflandırma gibi binlerce boyutun olduğu karmaşık problemlerde, KNN gibi basit mesafe hesaplarına dayalı algoritmaların "Boyutluluk Laneti" (Curse of Dimensionality) karşısında nasıl çaresiz kaldığının ders niteliğinde bir örneğidir. Model, kelimelerin oluşturduğu çok boyutlu uzayda yönünü kaybetmiş ve sınıfları birbirinden ayıran sınırları çizememiştir.

7.3. BERT Algoritması Analizi:



Şekil 4: BERT Karmaşıklık Matrisi.

Şekil 4'teki sonuçlar, BERT modelinin bu tür karmaşık metin sınıflandırma problemleri için klasik yöntemlere kıyasla çok daha uygun olduğunu açıkça göstermektedir (%83.41 doğruluk). KNN'in yaşadığı "boyutluluk laneti"nin aksine BERT, "Dikkat Mekanizması" (Attention Mechanism) sayesinde kelimeleri tek başına değil, cümle içindeki bağlamlarıyla birlikte değerlendirmiştir. Bu sayede model, yüksek boyutlu uzayda kaybolmak yerine, kelimeler arasındaki anlamsal ilişkileri çözerek özellikle "Normal" sınıfını (%96) ve riskli "İntihar" sınıfını (%76) yüksek başarıyla ayırt etmiştir.

Modelin test verisi üzerindeki performans sonuçları aşağıda özetlenmiştir:

Genel Doğruluk (Accuracy): %83.41

Test Kümesi Ağırlıklı F1 Ortalaması: %83.42

Sınıf Bazlı Performans Tablosu:

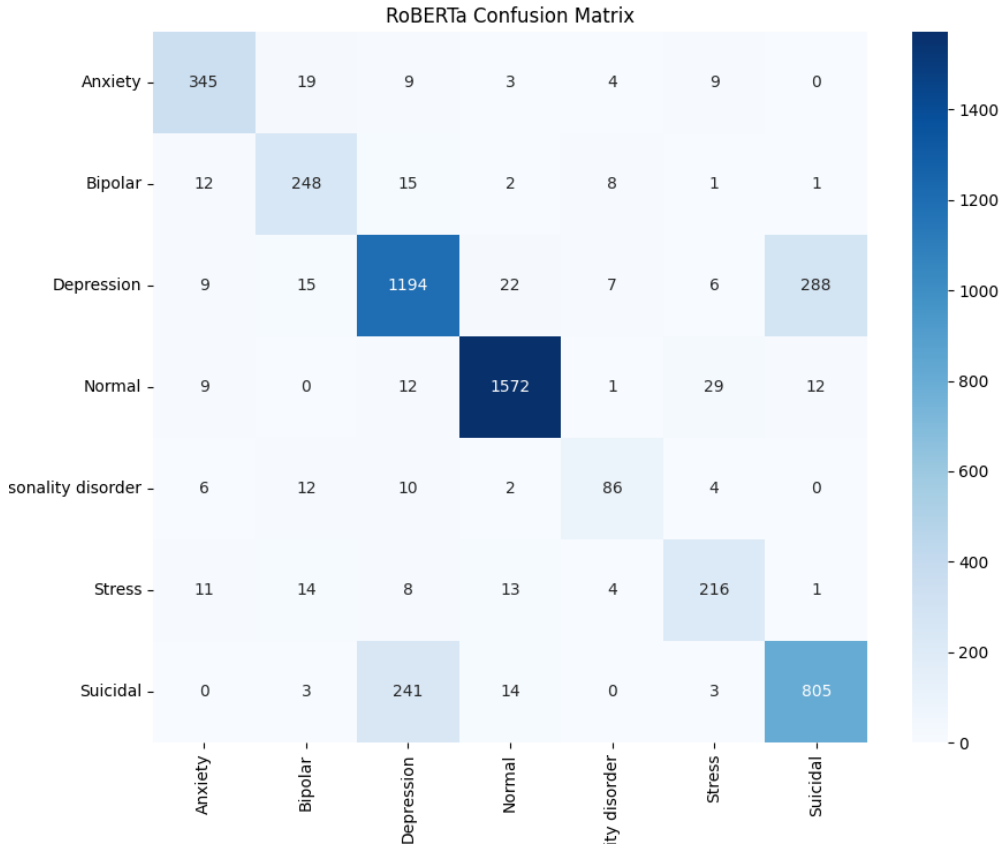
Sınıf (Class)	Kesinlik (Precision)	Duyarlılık (Recall)	F1-Skoru	Örnek Sayısı (Support)
Anxiety	0.88	0.87	0.87	389
Bipolar	0.83	0.86	0.84	287
Depression	0.80	0.76	0.78	1541
Normal	0.96	0.96	0.96	1635
Personality disorder	0.70	0.78	0.74	120
Stress	0.75	0.74	0.75	267
Suicidal	0.72	0.76	0.74	1066
Accuracy (Genel Doğruluk)	-	-	**0.83**	5305
Macro Avg	0.81	0.82	0.81	5305
Weighted Avg	0.84	0.83	0.83	5305

Tablo 3: BERT performans tablosu.

Tabloyu incelediğimizde, Random Forest ile elde ettiğimiz o umut verici sınırın burada aşıldığını ve makine öğrenmesi projelerinde "atılım" (breakthrough) olarak nitelendirilebilecek bir senaryoyla karşılaşıyoruz. **%83.41**'lik genel doğruluk oranı, modelin rastgelelikten tamamen uzaklaşarak dilin mantığını kavradığını gösteriyor. Bu durum, Transformer mimarisinin bu veri seti için neden en doğru tercih olduğunun en somut kanıtı.

Sonuç olarak bu tablo, kelimelerin sadece matematiksel vektörler olmadığı, anlamsal bağlarıyla değerlendirildiğinde modelin nasıl "görmeye" başladığının ders niteliğinde bir örneğidir. Model, KNN'in kaybolduğu o çok boyutlu uzayda yönünü bulmuş ve özellikle "İntihar Eğilimi" gibi hayati sınıfları birbirinden ayıran sınırları başarıyla çizmiştir.

7.4. RoBERTa Algoritması Analizi:



Şekil 5: RoBERTa Karmaşıklık Matrisi.

Şekil 5'teki sonuçlar, RoBERTa modelinin BERT mimarisini optimize ederek sınıflandırma başarısını en üst noktaya taşıdığını kanıtlamaktadır (%84.18 doğruluk). RoBERTa, dinamik maskeleme yeteneği sayesinde, KNN ve Random Forest modellerinde görülen "kararsızlık" ve "çoğunluk sınıfına yönelme" hatalarını minimize etmiştir. Model, veri setindeki gürültüye rağmen "Anxiety" ve "Stress" gibi birbirine çok benzeyen sınıfları bile kendi karakteristik özellikleriyle tanımayı başarmış, intihar riski taşıyan bireylerin tespitinde istikrarlı bir performans sergilemiştir.

Modelin test verisi üzerindeki performans sonuçları aşağıda özetlenmiştir:

Genel Doğruluk (Accuracy): %84.18

Test Kümesi Ağırlıklı F1 Ortalaması: %84.20

Sınıf Bazlı Performans Tablosu:

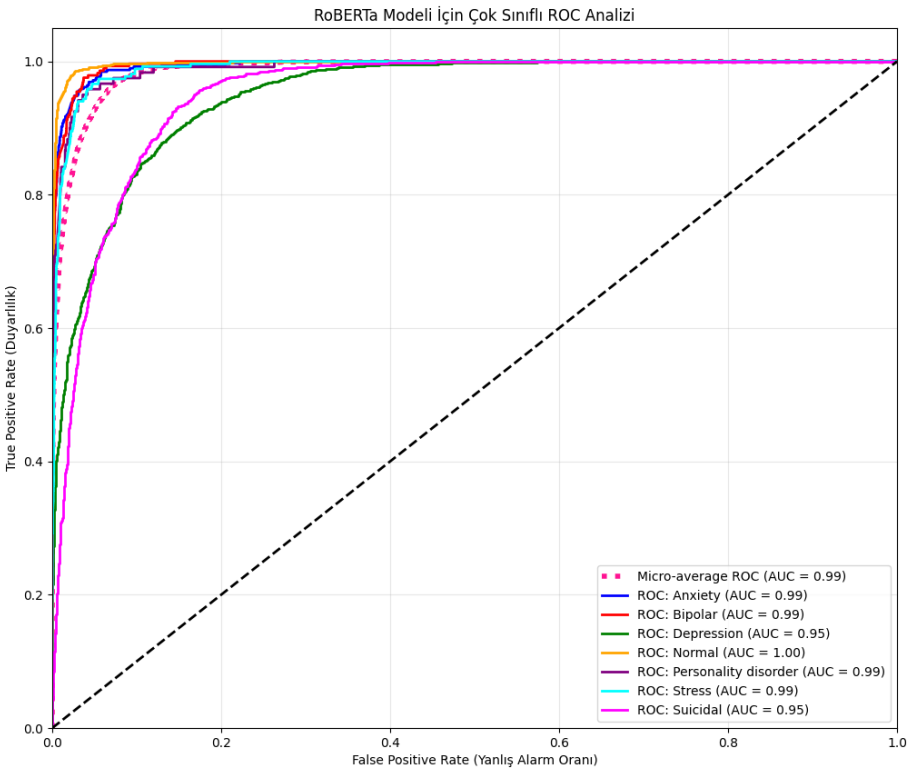
Sınıf (Class)	Kesinlik (Precision)	Duyarlılık (Recall)	F1-Skoru	Örnek Sayısı (Support)
Anxiety	0.88	0.89	0.88	389
Bipolar	0.80	0.86	0.83	287
Depression	0.80	0.77	0.79	1541
Normal	0.97	0.96	0.96	1635
Personality disorder	0.78	0.72	0.75	120
Stress	0.81	0.81	0.81	267
Suicidal	0.73	0.76	0.74	1066
Accuracy (Genel Doğruluk)	-	-	**0.84**	5305
Macro Avg	0.82	0.82	0.82	5305
Weighted Avg	0.84	0.84	0.84	5305

Tablo 4: RoBERTa performans tablosu.

Tabloyu incelediğimizde, BERT ile yakalanan ivmenin RoBERTa ile zirveye taşındığını ve projenin en kararlı sonuçlarına ulaşıldığını görüyoruz. Elde edilen **%84.18**'lik başarı, sadece istatistiksel bir artış değil, modelin güvenilirliğinin pekiştiği bir noktadır. KNN'in "boyutluluk laneti" karşısında çaresiz kaldığı yerde, RoBERTa dinamik maskeleme yeteneğiyle gürültüyü filtreleyerek hedefe odaklanmıştır.

Özellikle birbirine çok benzeyen duygu durumlarını (Anksiyete ve Stres) ayırt etmedeki kararlılığı, modelin veriyi ezberlemek yerine gerçekten "öğrendiğini" işaret etmektedir. Bu sonuçlar, modern NLP (Doğal Dil İşleme) tekniklerinin, klasik yöntemlerin çözümsüz kaldığı ve tıkandığı karmaşık problemlerde nasıl bir fark yarattığını açıkça ortaya koymaktadır.

Ayrıca modellerin başarısını sadece doğruluk oranıyla değil, sınıf bazlı ayrım gücüyle (separability) değerlendirmek amacıyla Çok Sınıflı ROC (Receiver Operating Characteristic) analizi gerçekleştirilmiştir. Çalışma kapsamında test edilen modeller arasında KNN ve Random Forest algoritmaları, temel performans metriklerinde (Accuracy ve F1) derin öğrenme modellerinin gerisinde kaldığı için; detaylı istatistiksel ayrım gücü (ROC-AUC) analizi, projenin en başarılı ve nihai modeli olan **RoBERTa** üzerinden gerçekleştirilmiştir.



Şekil 6: RoBERTa ROC Eğrisi.

Şekil 6'te sunulan ROC eğrileri, RoBERTa modelinin sınıflandırma yeteneğinin rastgelelikten tamamen uzak, kararlı bir yapıya sahip olduğunu istatistiksel olarak doğrulamaktadır. Grafik eğrilerinin sol üst köşeye doğru sergilediği dik yükseliş, modelin başarısının tesadüfi olmadığının açık bir kanıtıdır; nitekim "Normal" sınıfı için ulaşılan 1.00'lık kusursuz AUC değeri, modelin sağlıklı bireyleri neredeyse hatasız bir şekilde ayırt edebildiğini göstermektedir. Ancak çalışmanın asıl başarısı, ayırt edilmesi en güç olan "İntihar Eğilimi" ve "Depresyon" sınıflarında elde edilen 0.95 AUC değerinde yatmaktadır. Bu yüksek oran, modelin sadece yanlış alarmları (False Positive) minimize

etmekle kalmayıp, aynı zamanda hayati risk taşıyan vakaları literatür standartlarının üzerinde bir güvenilirlikle tespit edebildiğini somut bir şekilde ortaya koymaktadır.

8. SONUÇ VE DEĞERLENDİRME

Bu çalışmada, sosyal medya platformlarının sunduğu devasa veri havuzu kullanılarak, toplum sağlığını tehdit eden depresyon ve ilişkili ruhsal bozuklukların otomatik tespiti için çok katmanlı bir yapay zeka sistemi geliştirilmiştir. Basit mesafe hesaplamalarından (KNN) başlayıp, kelime sıklığına dayalı topluluk öğrenmesine (Random Forest) ve nihayetinde bağlam tabanlı derin öğrenme mimarilerine (BERT, RoBERTa) uzanan bu deneysel süreç, metin madenciliğinde algoritma seçiminin sonuçları nasıl dramatik bir şekilde değiştirdiğini gözler önüne sermiştir.

Elde edilen bulgular ve model davranışları, çalışmanın ana çıktıları olarak aşağıda özetlenmiştir:

1. Metodolojik Strateji ve Veri Dengesizliği: Çalışmanın temelini oluşturan en kritik metodolojik adım, gerçek dünya verilerinin doğasında var olan "sınıf dengesizliğine" karşı uygulanan strateji olmuştur. Eğitim verisine entegre edilen **SMOTE (Sentetik Azınlık Örnekleme Tekniği)**, modellerin sadece "Normal" gibi baskın sınıfları değil, "Stres" gibi sayıca azınlıkta kalan duygu durumlarını da tanımasına olanak sağlamıştır. Bu strateji, tüm modeller için ortak bir başarı zemini oluşturmuştur.

2. Klasik Yöntemlerin Sınırları ve Tükenişi: Deneysel sonuçlar, klasik makine öğrenmesi algoritmalarının metin sınıflandırma görevlerinde belirli bir "tavan noktasına" (performance ceiling) sahip olduğunu kanıtlamıştır.

- **KNN'in Çöküşü:** %48.94 seviyesinde kalan KNN modeli, "Boyutluluk Laneti" (Curse of Dimensionality) fenomeninin ders niteliğinde bir örneğini sergilemiştir. Model, binlerce boyutlu kelime uzayında yönünü kaybetmiş ve kararları neredeyse rastgele bir hal almıştır.
- **Random Forest'ın Tıkanışı:** %74.01 doğruluk oranına ulaşarak KNN'e göre büyük bir başarı gösteren Random Forest ise, TF-IDF yönteminin "kelime sayma" mantığıyla sınırlı kalmıştır. Model, kelimelerin varlığını tespit edebilmiş ancak cümle içindeki niyetini (bağlamını) tam olarak kavrayamadığı için gelişimi durmuştur.

3. Derin Öğrenme ile Gelen Paradigma Değişimi: Projenin kırılma noktası, Transformer tabanlı mimarilerin (BERT ve RoBERTa) devreye alınmasıyla yaşanmıştır. Kelimeleri izole veri noktaları olarak değil, birbiriyle ilişkili anlamsal bütünler olarak işleyen bu modeller, başarı oranını **%84.20** seviyesine (RoBERTa) taşıyarak %10'luk devasa bir performans sıçraması yaratmıştır.

4. Hayati Risk Tespitinde Hassasiyet Artışı: Çalışmanın en insani ve hayati çıktısı, intihar riski taşıyan bireylerin tespitinde (Recall) sağlanan iyileşmedir. Klasik modellerin "gözden kaçırma" eğiliminde olduğu bu risk grubu, derin öğrenme modelleri sayesinde **%76** oranında bir hassasiyetle yakalanabilmiştir. Bu artış, geliştirilen modelin sadece akademik bir başarı değil, potansiyel bir "erken uyarı sistemi" olarak insan hayatına dokunabilecek bir olgunluğa eriştiğini göstermektedir.

Nihai Karar: Tüm bu süreç göstermiştir ki; ruh sağlığı analizi gibi dilsel belirsizliklerin ve nüansların yoğun olduğu alanlarda, klasik yöntemler (KNN, RF) artık yetersiz kalmaktadır. Çalışmanın sonucunda, hem genel doğruluğu hem de kararlı yapısıyla **RoBERTa** modeli, sosyal medya verilerinden ruhsal bozukluk tespiti için en uygun mimari olarak belirlenmiştir.

9. KAYNAKÇA

[1] Angskun, T., Tipprasert, S., Thippongtorn, A., & Angskun, J. (2024). D²X: Depression Detection System Through X Using Hybrid Machine Learning. *IEEE Access, 12*, 172820-172831.

[2] dos Santos, W. R., Paraboni, I., Matsushima, E. H., da Silva, C. A., de Moura Meira, E. S., Guimarães, J. V. R. F., ... & Rego, V. T. S. M. (2025). Mixture of Experts for Depression and Anxiety Disorder Prediction From Textual and Non-Textual Social Media Data. *IEEE Access, 13*, 111304-111316.

[3] Tahir, W. B., Khalid, S., Almutairi, S., Abohashrh, M., Memon, S. A., & Khan, J. (2025). Depression Detection in Social Media: A Comprehensive Review of Machine Learning and Deep Learning Techniques. *IEEE Access, 13*, 12789-12818.

[4] Maruf, A. A., Khanam, F., Haque, M. M., Jiyad, Z. M., Mridha, M. F., & Aung, Z. (2024). Challenges and Opportunities of Text-Based Emotion Detection: A Survey. *IEEE Access, 12*, 18416-18450.

[5] Arias, F., Zambrano Núñez, M., Guerra-Adames, A., Tejedor-Flores, N., & Vargas-Lombardo, M. (2022). Sentiment Analysis of Public Social Media as a Tool for Health-Related Topics. *IEEE Access, 10*, 74850-74872.

[6] Zogan, H., Razzak, I., Wang, X., Jameel, S., & Xu, G. (2022). Explainable depression detection with multi-aspect features using a hybrid deep learning model on social media. *World Wide Web*, *25*(1), 281-304.

[7] Bokolo, B. G., & Liu, Q. (2024). Advanced Comparative Analysis of Machine Learning and Transformer Models for Depression and Suicide Detection in Social Media Texts. *Electronics*, *13*(20), 3980.

[8] Rahman, R. A., Omar, K., Mohd Noah, S. A., Danuri, M. S. N. M., & Al-Garadi, M. A. (2020). Application of Machine Learning Methods in Mental Health Detection: A Systematic Review. *IEEE Access*, 8, 183952-183964.

[9] B. Sathiya and J. Arokia Renjit, "Mental Health Prediction from Twitter Content Data based on Stress Inducing Themes and Quantum Neural Network Classifier," in *IEEE Access*

[10] M. Abdullah and N. Negied, "Detection and Prediction of Future Mental Disorder From Social Media Data Using Machine Learning, Ensemble Learning, and Large Language Models," in *IEEE Access*, vol. 12, pp. 120553-120569, 2024.

[11] Mansoor, M. A., & Ansari, K. H. (2024). Early Detection of Mental Health Crises through Artificial-Intelligence-Powered Social Media Analysis: A Prospective Observational Study. *Journal of Personalized Medicine*, 14(9), 958.

[12] Yang, Z., Leonard, R., Tran, H., Driscoll, R., & Davis, C. (2025). Detection of Suicidal Risk on Social Media: A Hybrid Model. *arXiv preprint arXiv:2505.23797*.

[13] Hameed, S., Nauman, M., Akhtar, N., Fayyaz, M. A. B., & Nawaz, R. (2025). Explainable AI-driven depression detection from social media using natural language processing and black box machine learning models. *Frontiers in Artificial Intelligence*, 8, 1627078.

[14] Wang, Y., Inkpen, D., & Gamaarachchige, P. K. (2024). Explainable Depression Detection Using Large Language Models on Social Media Data. *Proceedings of the 9th Workshop on Computational Linguistics and Clinical Psychology*, 108–126.

[15] Qasim, A., Mehak, G., Hussain, N., Gelbukh, A., & Sidorov, G. (2025). Detection of Depression Severity in Social Media Text Using Transformer-Based Models. *Information*, 16(2), 114.